ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TT, CLC & POHE
…….o0o…….

BÀI TẬP NHÓM

HỌC PHẦN: KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

<u>CHỦ ĐỀ</u>: PHÂN TÍCH CÁC YẾU TỐ HÓA LÝ ẢNH HƯỞNG ĐẾN CHẤT LƯỢNG RƯỢU VANG ĐỎ

Giảng viên bộ môn: TS. Trần Đức Minh
Lớp: TOKT1138(126)CLC_57
Nhóm thực hiện: 7

Hà Nội – 11/2026

ĐÁNH GIÁ THÀNH VIÊN

Họ và tên	MSV	Nhiệm vụ đảm nhận	Mức độ đóng góp
Ngô Hà Phương (Nhóm trưởng)	11244211	- Phân công nhiệm vụ và thời hạn hoàn thành, theo dõi tiến độ thực hiện của các thành viên. - Phụ trách chính Giai đoạn 3: Phân tích và trực quan hóa dữ liệu	100%
Đồng Bảo Anh	11247864	- Phụ trách chính Giai đoạn 3: Phân tích và trực quan hóa dữ liệu	100%
Đoàn Ngọc Linh	11248146	- Phụ trách chính Giai đoạn 4: Đánh giá tác động và khuyến nghị	100%
Phạm Thị Thúy Nga	11241810	- Phụ trách chính Giai đoạn 2: Tiền xử lý và làm sạch dữ liệu	100%
Giang Thị Huyền Trang	11240426	- Phụ trách chính Giai đoạn 1: Thu thập và đánh giá dữ liệu ban đầu	100%

BÁO CÁO DỰ ÁN PHÂN TÍCH DỮ LIỆU

Chuyên đề: Phân tích mối quan hệ giữa các chỉ tiêu hóa lý và chất lượng cảm quan của rượu vang đỏ (Red Wine Quality)

Nguồn dữ liệu: UCI Machine Learning Repository (Cortez et al., 2009 - Đại học Minho và CVRVV, Bồ Đào Nha)

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1. Nguồn dữ liệu và mục tiêu bài toán

Tập dữ liệu lựa chọn là Red Wine Quality Dataset từ kho lưu trữ UCI Machine Learning Repository, xuất phát từ công trình nghiên cứu của P. Cortez, A. Cerdeira, F. Almeida, T. Matos và J. Reis (2009) phối hợp giữa Đại học Minho và Ủy ban Giám sát Rượu vang vùng Vinho Verde (CVRVV), Bồ Đào Nha. Tập dữ liệu gốc gồm 1 file định dạng CSV với 1,599 dòng quan sát và 12 thuộc tính (gồm 11 biến hóa lý và 1 biến chất lượng cảm quan). Mục tiêu là đánh giá thống kê mối quan hệ giữa các chỉ tiêu hóa học và điểm số đánh giá cảm quan nếm thử từ các chuyên gia, từ đó đề xuất các định hướng kiểm soát chất lượng mẻ ủ trong thực tế.

2. Danh mục các thuộc tính trong tập dữ liệu

STT	Tên trường	Đơn vị	Ý nghĩa hóa lý / chuyên môn	Vai trò
1	fixed acidity	g(tartaric acid)/dm³	Axit cố định (chủ yếu là axit tartaric), tạo độ chua nền tảng	Biến độc lập
2	volatile acidity	g(acetic acid)/dm³	Axit dễ bay hơi (chủ yếu là axit axetic), nếu cao gây mùi giấm hỏng	Biến độc lập
3	citric acid	g/dm³	Axit xitric, bổ sung độ tươi mát và thanh nhã cho rượu	Biến độc lập
4	residual sugar	g/dm³	Lượng đường còn sót lại sau quá trình lên men	Biến độc lập
5	chlorides	g(NaCl)/dm³	Hàm lượng muối khoáng natri clorua trong rượu	Biến độc lập
6	free sulfur dioxide	mg/dm³	Hàm lượng SO_2 ở các dạng tự do trong dung dịch (khí hòa tan SO_2, HSO_3^-, SO_3^{2-})	Biến độc lập
7	total sulfur dioxide	mg/dm³	Tổng lượng SO_2 (gồm dạng tự do và dạng liên kết với các hợp chất khác)	Biến độc lập
8	density	g/cm³	Khối lượng riêng của rượu, phụ thuộc vào nồng độ cồn và lượng đường dư	Biến độc lập
9	pH	Thang 0-14	Độ pH đo tính axit của dung dịch rượu	Biến độc lập
10	sulphates	g(K_2SO_4)/dm³	Hàm lượng sunfat (sulphates), được biểu diễn theo potassium sulphate (K_2SO_4), là một chỉ tiêu hóa lý trong thành phần rượu vang	Biến độc lập
11	alcohol	% vol	Nồng độ cồn ethanol sinh ra sau khi lên men	Biến độc lập
12	quality	Điểm 0-10	Điểm chất lượng cảm quan (quality), được xác định bằng trung vị (median) của ít nhất 3 lần đánh giá từ các chuyên gia nếm thử, trên thang điểm 0–10	Biến mục tiêu

3. Rà soát hiện trạng dữ liệu gốc (1,599 mẫu)

- Kiểu dữ liệu: Toàn bộ 11 biến hóa lý đều thuộc kiểu số thực liên tục (float64), tương thích hoàn toàn với phép đo phòng thí nghiệm. Biến quality thuộc kiểu số nguyên rời rạc (int64) với dải giá trị từ 3 đến 8. Không có trường nào bị lưu nhầm dạng chuỗi văn bản.
- Giá trị khuyết thiếu: Tập dữ liệu đạt tỷ lệ hoàn thiện 100%, có đúng 0 giá trị NaN/Null trên toàn bộ 1,599 quan sát.
- Tính nhất quán: Dữ liệu đơn bảng, không có liên kết khóa ngoại với bảng ngoài nên không phát sinh vấn đề bất đồng bộ khóa.
- Bảng thống kê mô tả tổng quan trên tập 1,599 mẫu gốc ghi nhận: nồng độ cồn trung bình là 10.42% (IQR = 1.60), đường dư trung bình 2.54 g/dm³ (IQR = 0.70), độ pH trung bình 3.31 (IQR = 0.19) và điểm chất lượng trung vị là 6.00 (trung bình 5.64).

GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

1. Xử lý dữ liệu trùng lặp (Deduplication) kèm Phân tích độ nhạy

Rà soát đối chiếu toàn bộ 12 thuộc tính ghi nhận có 240 dòng trùng lặp hoàn toàn (chiếm 15.01% tổng số 1,599 quan sát gốc). Do tập dữ liệu UCI không cung cấp mã định danh mẫu rượu (Sample ID), ta không thể khẳng định chắc chắn 240 dòng này là lỗi nhập liệu hay là các mẫu rượu độc lập ngẫu nhiên có cùng các chỉ tiêu đo lường. Quyết định loại bỏ 240 bản ghi lặp được đưa ra nhằm mục đích kỹ thuật là tránh hiện tượng **Data Leakage** (rò rỉ dữ liệu cùng bản ghi vào cả tập train và test khi phân chia mô hình).

Để kiểm tra xem việc loại bỏ 240 dòng này có làm thay đổi đáng kể các hệ số tương quan của 7 biến được khảo sát hay không, nhóm thực hiện **Phân tích độ nhạy (Sensitivity Analysis)**: so sánh tương quan Pearson giữa 1,599 mẫu gốc và 1,359 mẫu sau khử trùng lặp (xuất chi tiết 6 chữ số thập phân từ thực nghiệm):

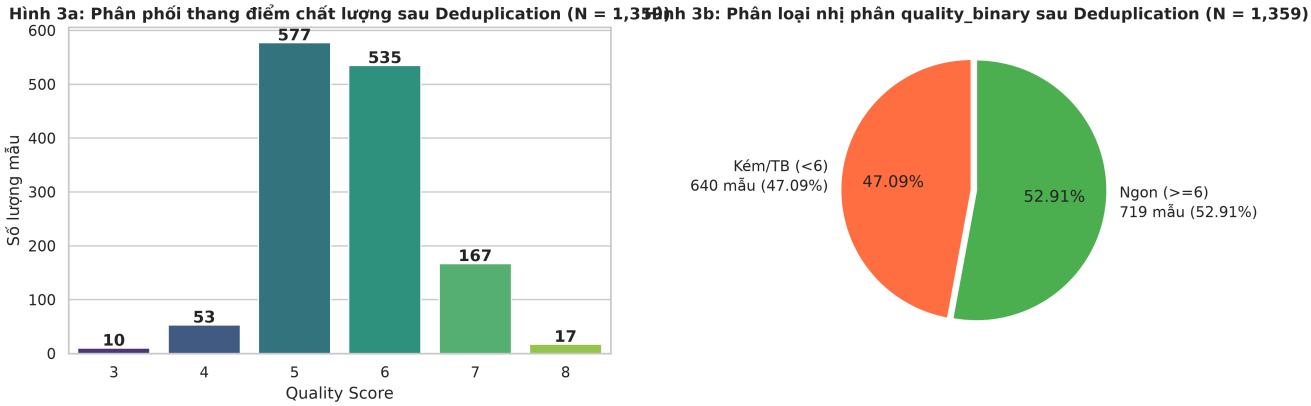
Thuộc tính	Pearson r (1,599 mẫu gốc)	Pearson r (1,359 mẫu sau dedup)	Chênh lệch (Delta r)
alcohol	0.476166	0.480343	+0.004177
volatile acidity	-0.390558	-0.395214	-0.004656
sulphates	0.251397	0.248835	-0.002562
citric acid	0.226373	0.228057	+0.001685
residual sugar	0.013732	0.013640	-0.000091
chlorides	-0.128907	-0.130988	-0.002082
total sulfur dioxide	-0.185100	-0.177855	+0.007245

Nhận xét: Độ lệch hệ số tương quan lớn nhất trong 7 biến được khảo sát chỉ là |delta r| = 0.007245 (ở total sulfur dioxide). Kết quả này cho thấy bước khử trùng lặp **không làm thay đổi đáng kể các hệ số tương quan của 7 biến được khảo sát**.

2. Phân bố điểm chất lượng sau Deduplication (1,359 mẫu)

Toàn bộ phân phối bên dưới được đồng bộ trên quần thể **1,359 mẫu duy nhất** sau khử trùng lặp: điểm 3 (10 mẫu, 0.74%), điểm 4 (53 mẫu, 3.90%), điểm 5 (577 mẫu, 42.46%), điểm 6 (535 mẫu, 39.37%), điểm 7 (167 mẫu, 12.29%) và điểm 8 (17 mẫu, 1.25%). Thang điểm 5 và 6 chiếm tới 81.83% dữ liệu. Nhóm tạo nhãn nhị phân quality_binary: **0 (Kém/TB: < 6, gồm 640 mẫu, chiếm 47.09%)** và **1 (Ngon: ≥ 6, gồm 719 mẫu, chiếm 52.91%)**.

Hình 3: Phân bố điểm chất lượng gốc và tỷ lệ cân bằng sau khi tạo nhãn nhị phân (N = 1,359)

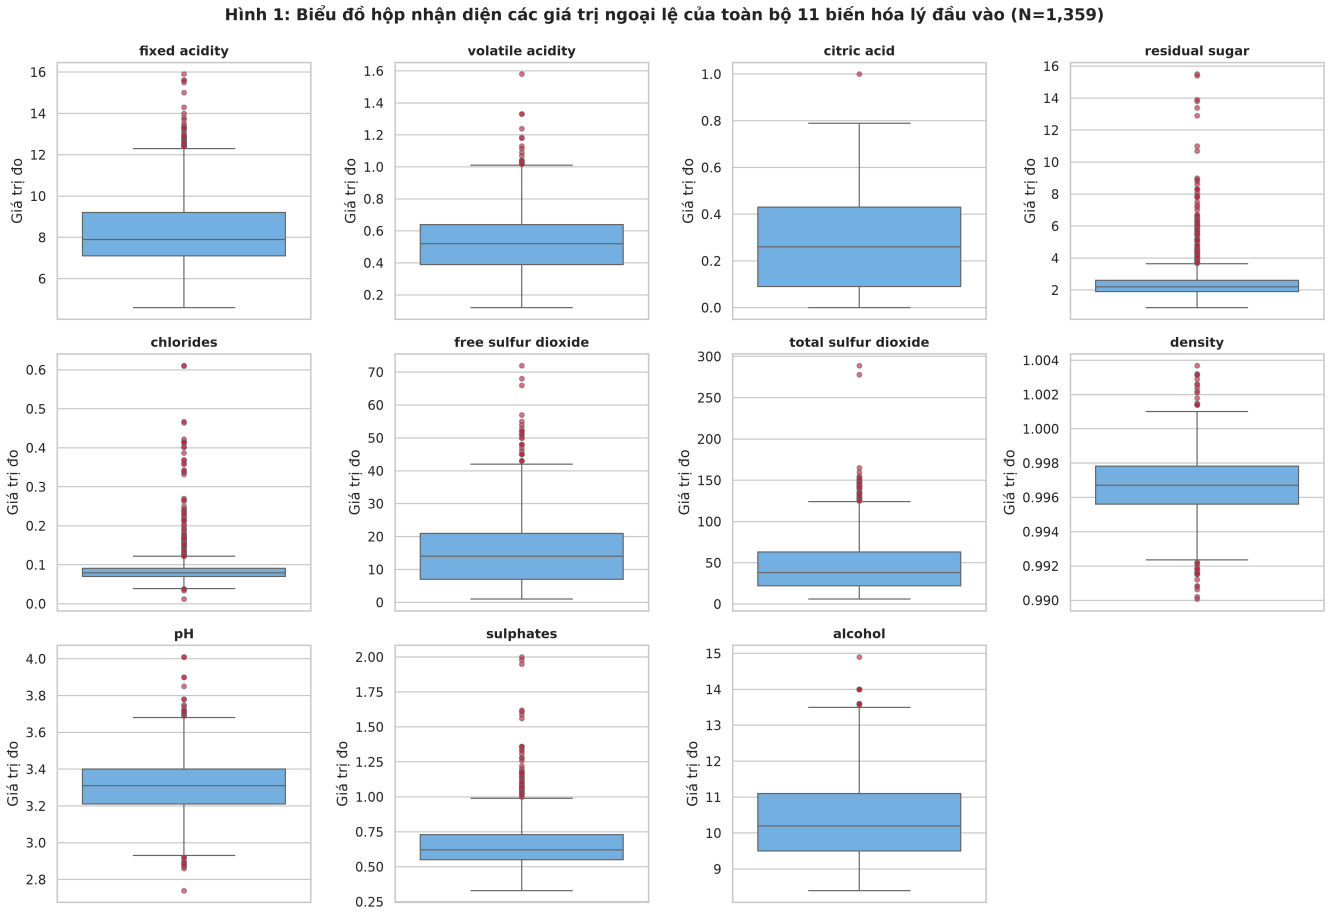


Hình 3: Phân bố điểm chất lượng gốc và tỷ lệ cân bằng sau khi tạo nhãn nhị phân (N=1,359)

3. Nhận diện và định lượng ngoại lệ trên toàn bộ 11 biến đầu vào sau khử trùng lặp (1,359 mẫu)

Nhóm sử dụng phương pháp Biên phân vị (IQR) để phát hiện ngoại lệ với ngưỡng dưới Q1 - 1.5*IQR và ngưỡng trên Q3 + 1.5*IQR trên toàn bộ 11 biến hóa lý đầu vào. Biến mục tiêu quality là thang đo thứ bậc cảm quan (ordinal scale từ 3 đến 8); các điểm cực biên 3 và 8 là kết quả đánh giá thực tế của chuyên gia, không được xem là dữ liệu lỗi hay ngoại lệ cần loại bỏ.

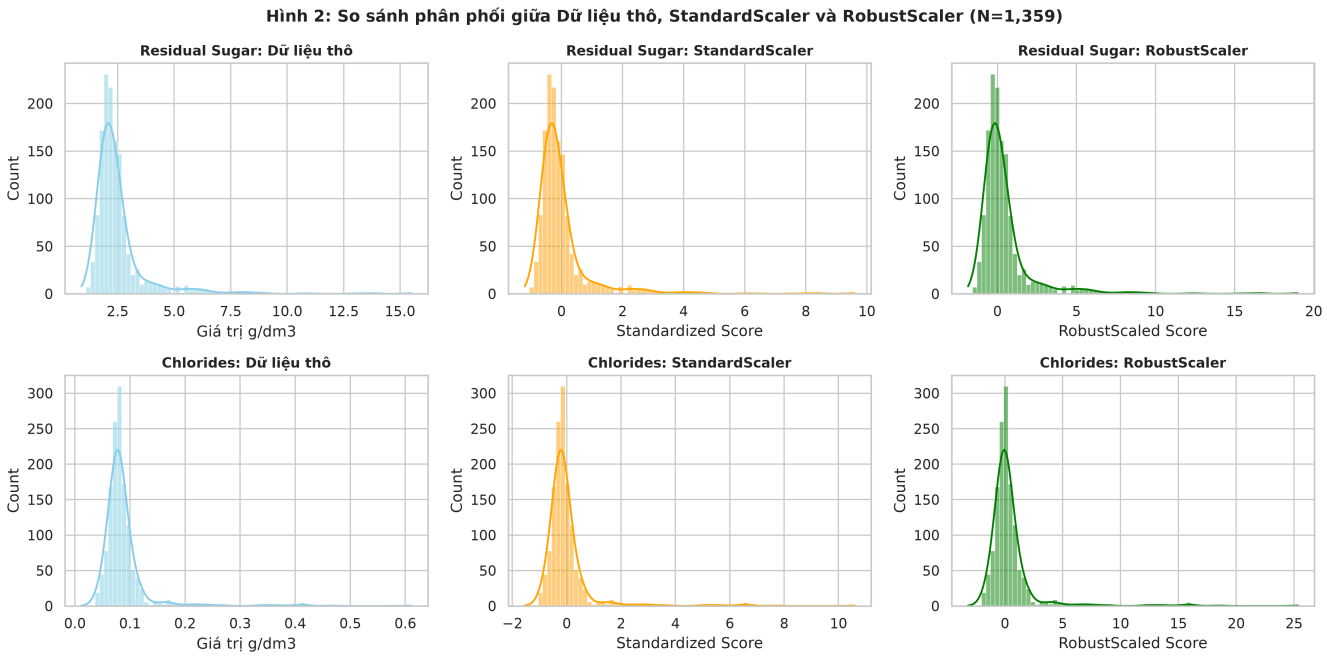
Thuộc tính	Q1	Median	Q3	IQR	Ngưỡng dưới	Ngưỡng trên	Số Outlier	Tỷ lệ Outlier
fixed acidity	7.10	7.90	9.20	2.10	3.95	12.35	41	3.02%
volatile acidity	0.39	0.52	0.64	0.25	0.015	1.015	19	1.40%
citric acid	0.09	0.26	0.43	0.34	-0.42	0.94	1	0.07%
residual sugar	1.90	2.20	2.60	0.70	0.85	3.65	126	9.27%
chlorides	0.070	0.079	0.091	0.021	0.0385	0.1225	87	6.40%
free sulfur dioxide	7.0	14.0	21.0	14.0	-14.0	42.0	26	1.91%
total sulfur dioxide	22.0	38.0	63.0	41.0	-39.5	124.5	45	3.31%
density	0.9956	0.9967	0.9978	0.0022	0.9923	1.0012	35	2.58%
pH	3.21	3.31	3.40	0.19	2.925	3.685	28	2.06%
sulphates	0.55	0.62	0.73	0.18	0.28	1.00	55	4.05%
alcohol	9.50	10.20	11.10	1.60	7.10	13.50	12	0.88%



Hình 1: Biểu đồ hộp nhận diện các giá trị ngoại lệ của toàn bộ 11 biến hóa lý đầu vào (N=1,359)

4. Giải trình kỹ thuật: Định lượng tỷ lệ dòng Outlier, Winsorization & RobustScaler

- Định lượng thực tế tỷ lệ mẫu bị ảnh hưởng (Union of Outliers): Do một mẫu rượu có thể đồng thời là ngoại lệ ở nhiều thuộc tính, kết quả tính toán tập hợp các dòng có ít nhất một giá trị ngoại lệ (outlier_mask.any(axis=1)) ghi nhận có đúng **340 / 1,359 dòng (chiếm 25.02% tổng số mẫu)**. Do đó, nếu xóa bỏ toàn bộ các dòng này, ta sẽ làm mất tới 1/4 dung lượng quan sát của tập dữ liệu. Ngoài ra, tập dữ liệu gốc không chứa thông tin về phân hạng thương mại hay giá bán để khẳng định các giá trị cực biên là sai số nhập liệu. Vì vậy, nhóm áp dụng kỹ thuật Winsorization (Capping tại biên 1.5*IQR) trên 11 biến đầu vào nhằm kiểm soát tác động của các giá trị cực đoan lên thuật toán mà vẫn bảo toàn đủ 1,359 quan sát.
- *Lưu ý phương pháp quan trọng:* **Phần lớn các phân tích suy luận thống kê (Pearson, Spearman, Welch's t-test và Welch ANOVA) cùng các biểu đồ Figure 4–7 sử dụng dữ liệu sau Winsorization. Riêng Figure 1–3 được xây dựng trên dữ liệu sau khử trùng lặp nhưng chưa Winsorization nhằm phản ánh đặc điểm phân phối ban đầu và minh họa các bước tiền xử lý.**
- *Bản chất của RobustScaler:* RobustScaler giúp giảm ảnh hưởng của các giá trị cực đoan đến tham số chuẩn hóa (dựa trên Median và IQR), **nhưng không trực tiếp loại bỏ các giá trị ngoại lệ hoặc khắc phục độ lệch phân phối (skewness)**.



Hình 2: So sánh phân phối giữa Dữ liệu thô, StandardScaler và RobustScaler (N=1,359)

GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU

1. So sánh hệ số tương quan Pearson trước và sau Winsorization trên toàn bộ 11 biến đầu vào

Để đánh giá tác động định lượng của kỹ thuật Winsorization Capping, nhóm tiến hành tính toán song song hệ số tương quan Pearson trên toàn bộ 11 biến hóa lý đầu vào giữa dữ liệu sạch gốc chưa Capping (1,359 mẫu) và dữ liệu sau Winsorization:

Thuộc tính	Pearson r (Gốc chưa Capping)	p-value (Gốc)	Pearson r (Sau Winsorization)	p-value (Winsorized)	Chênh lệch (Delta r)
alcohol	+0.4803	2.28e-79	+0.4827	3.03e-80	+0.0024
volatile acidity	-0.3952	4.93e-52	-0.3921	3.49e-51	+0.0031
sulphates	+0.2488	1.26e-20	+0.3306	4.99e-36	+0.0818
citric acid	+0.2281	1.71e-17	+0.2287	1.39e-17	+0.0006
chlorides	-0.1310	1.26e-06	-0.1938	5.82e-13	-0.0628
total sulfur dioxide	-0.1779	4.02e-11	-0.1968	2.49e-13	-0.0189
density	-0.1843	7.66e-12	-0.1852	5.99e-12	-0.0009
fixed acidity	+0.1190	1.09e-05	+0.1206	8.22e-06	+0.0016
pH	-0.0552	4.17e-02	-0.0594	2.85e-02	-0.0042
free sulfur dioxide	-0.0505	6.29e-02	-0.0520	5.52e-02	-0.0016
residual sugar	+0.0136	6.15e-01	+0.0191	4.81e-01	+0.0055

Nhận xét: Các chỉ số alcohol, volatile acidity, citric acid, fixed acidity, density và residual sugar hầu như không thay đổi hệ số tương quan sau Winsorization ($|\text{delta r}| \leq 0.0055$). Riêng chỉ số sulphates tăng hệ số tương quan từ +0.2488 lên +0.3306 và chlorides giảm từ -0.1310 xuống -0.1938 do việc giới hạn các giá trị ngoại lệ đuôi dài giúp phản ánh mối tương quan tuyến tính ở phần lớn dữ liệu tập trung rõ ràng hơn.

2. Đối chiếu Tương quan Tuyến tính Pearson và Tương quan Thứ bậc Spearman (Toàn bộ 11 biến)

Do biến mục tiêu quality là thang đo thứ bậc rời rạc từ 3 đến 8, nhóm bổ sung phép kiểm tra tương quan thứ bậc Spearman trên toàn bộ 11 biến hóa lý đầu vào để đánh giá độ bền (robustness) của mối quan hệ đơn điệu:

Thuộc tính	Pearson r (Winsorized)	p-value (Pearson)	Spearman rho (Gốc)	Spearman rho (Winsorized)	p-value (Spearman)	Đánh giá độ bền
alcohol	+0.4827	3.03e-80	+0.4880	**+0.4880**	3.17e-82	Rất nhất quán (Mối liên hệ thuận mạnh mẽ)
volatile acidity	-0.3921	3.49e-51	-0.3874	**-0.3874**	6.63e-50	Rất nhất quán (Mối liên hệ nghịch rõ rệt)
sulphates	+0.3306	4.99e-36	+0.3806	**+0.3811**	3.21e-48	Rất nhất quán (Mối liên hệ thuận)
citric acid	+0.2287	1.39e-17	+0.2194	**+0.2194**	2.80e-16	Nhất quán
chlorides	-0.1938	5.82e-13	-0.2044	**-0.2042**	2.92e-14	Nhất quán
total sulfur dioxide	-0.1968	2.49e-13	-0.1966	**-0.1970**	2.35e-13	Rất nhất quán
density	-0.1852	5.99e-12	-0.1843	**-0.1843**	7.63e-12	Rất nhất quán
fixed acidity	+0.1206	8.22e-06	+0.1117	**+0.1117**	3.71e-05	Nhất quán
pH	-0.0594	2.85e-02	-0.0427	**-0.0427**	1.15e-01	Tương quan yếu
free sulfur dioxide	-0.0520	5.52e-02	-0.0587	**-0.0587**	3.04e-02	Tương quan yếu
residual sugar	+0.0191	4.81e-01	+0.0257	**+0.0249**	3.59e-01	Nhất quán (Không có ý nghĩa thống kê)

3. Thiết lập và kiểm định giả thuyết thống kê (kết hợp Welch's t-test)

Kiểm định tính đồng nhất phương sai giữa hai nhóm nhãn (Levene's test) cho thấy biến alcohol có $p = 3.94e\text{-}28 < 0.05$ và sulphates có $p = 0.0168 < 0.05$. Do phương sai hai nhóm không đồng nhất, nhóm sử dụng **Welch's t-test (equal_var=False)**:

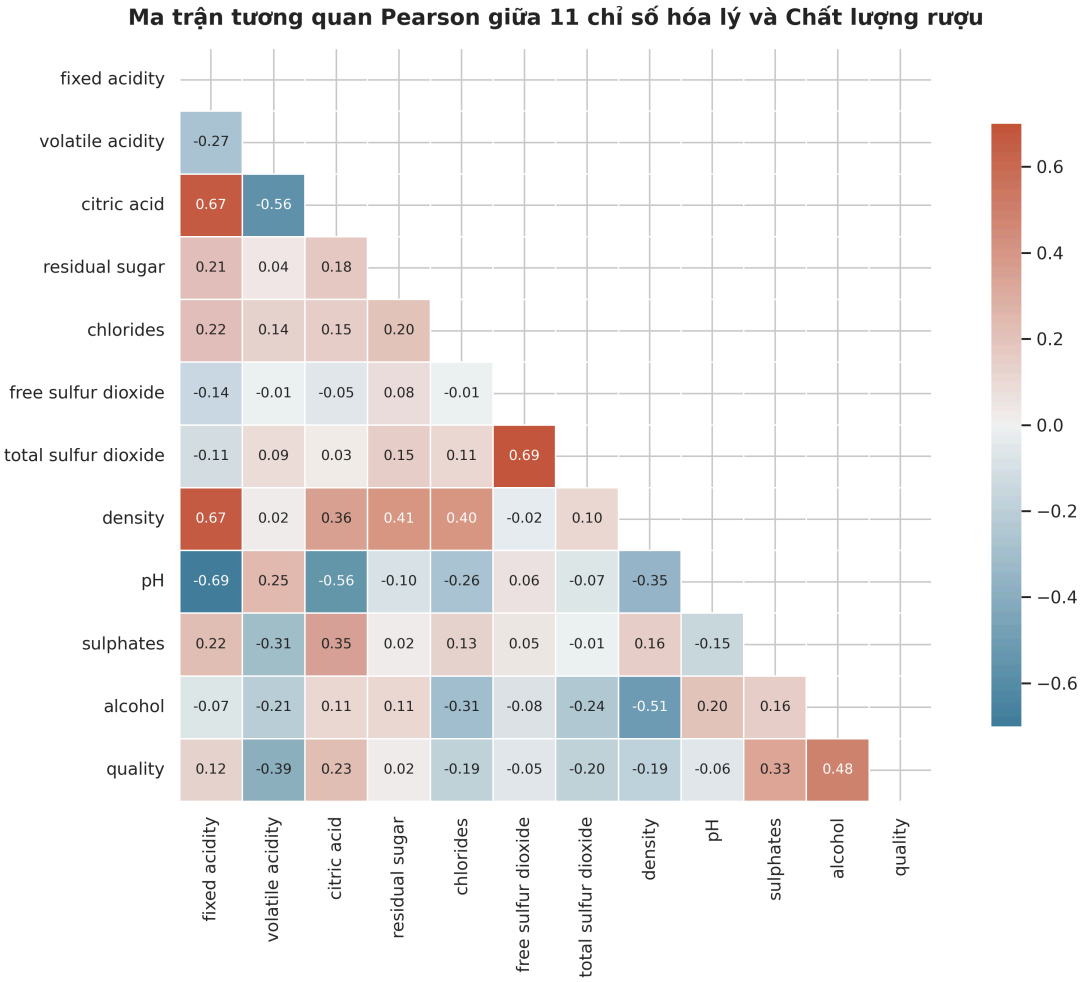
Giả thuyết	Nội dung	Kết quả kiểm định định lượng	Kết luận chuẩn xác
H1	Tương quan giữa alcohol và điểm chất lượng	Pearson r = +0.4827 (p = 3.03e-80) Welch's t-test: t = 18.93 (p = 1.12e-70) Mean nhóm <6: 9.92%, Mean nhóm ≥6: 10.88%	**Có bằng chứng thống kê ủng hộ mối tương quan thuận.** Nhóm điểm cao có nồng độ cồn trung bình cao hơn rõ rệt.
H2	Tương quan giữa volatile acidity và điểm chất lượng	Pearson r = -0.3921 (p = 3.49e-51) Welch's t-test: t = -12.76 (p = 3.23e-35) Mean nhóm <6: 0.59 g/dm³, Mean nhóm ≥6: 0.47 g/dm³	**Có bằng chứng thống kê ủng hộ mối tương quan nghịch.** Hàm lượng axit bay hơi cao liên hệ với điểm chất lượng thấp hơn.
H3	Tương quan giữa residual sugar và điểm chất lượng	Pearson r = +0.0191 (p = 0.481 > 0.05) Welch's t-test: t = -0.190 (p = 0.850 > 0.05) Mean nhóm <6: 2.33 g/dm³, Mean nhóm ≥6: 2.32 g/dm³	**Chưa đủ bằng chứng thống kê để xác định mối tương quan tuyến tính hay đơn điệu** giữa đường dư và điểm chất lượng trong tập mẫu.
H4	Tương quan giữa sulphates và điểm chất lượng	Pearson r = +0.3306 (p = 4.99e-36) Welch's t-test: t = 10.85 (p = 2.42e-26) Mean nhóm <6: 0.61 g/dm³, Mean nhóm ≥6: 0.69 g/dm³	**Có bằng chứng thống kê ủng hộ mối tương quan thuận** giữa hàm lượng sulphates và điểm chất lượng cảm quan.

4. Phân tích Welch ANOVA và Kiểm định Hậu kiểm Games-Howell cho Alcohol

Kiểm định Levene trên cả 6 nhóm điểm cho W = 19.22 (p = 1.61e-18, phương sai 6 nhóm không đồng nhất). Phép kiểm định Standard ANOVA cho F = 105.04 (p = 8.59e-94) và Welch ANOVA hiệu chỉnh cho F = 103.97 (p_val = 3.56e-28 tính bằng survival function stats.f.sf). Do phương sai và cỡ mẫu giữa các nhóm không đồng đều, nhóm sử dụng **phép kiểm định hậu kiểm Games-Howell** (thay cho Tukey HSD vốn giả định phương sai đồng nhất). Kết quả cụ thể như sau:

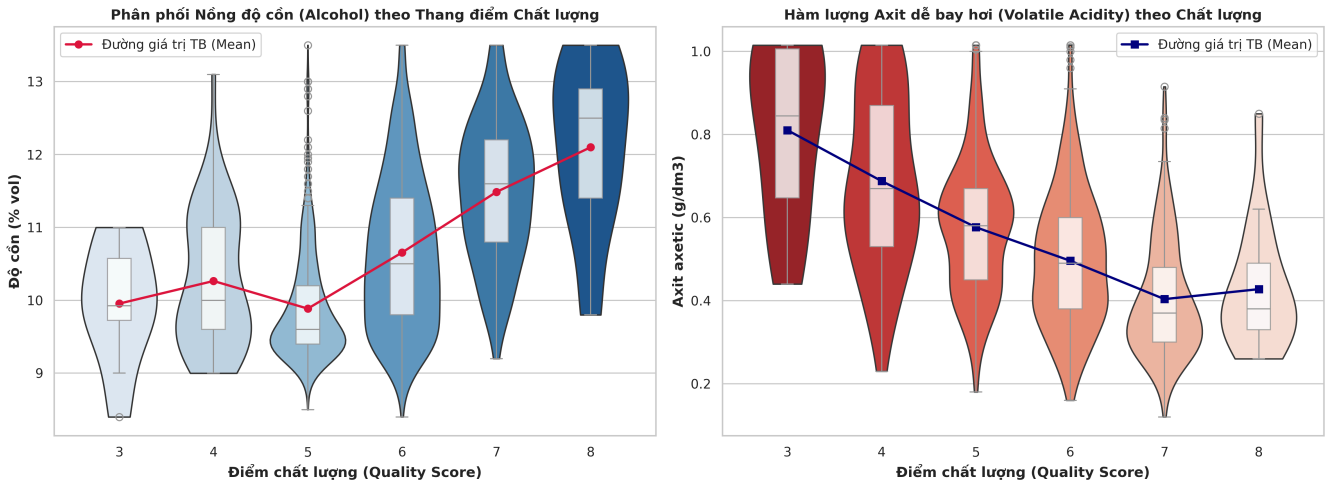
- **Các cặp KHÔNG có sự khác biệt có ý nghĩa thống kê (pval > 0.05):** Cặp (3, 4) pval=0.884; (3, 5) pval=0.9998; (3, 6) pval=0.170; cặp (4, 5) pval=0.060; cặp (4, 6) pval=0.059; và cặp (7, 8) pval=0.312.
- **Các cặp CÓ sự khác biệt có ý nghĩa thống kê (pval < 0.05):** Cặp (3, 7) pval=0.0017; (3, 8) pval=0.0001; cặp (4, 7) pval=2.11e-11; (4, 8) pval=5.18e-05; cặp (5, 6) pval<0.001; (5, 7) pval<0.001; (5, 8) pval=6.79e-06; cặp (6, 7) pval=3.56e-14; và (6, 8) pval=0.0010.

5. Trực quan hóa có mục tiêu và diễn giải chuyên sâu



Hình 4: Ma trận nhiệt tương quan Pearson giữa các chỉ tiêu hóa lý và điểm chất lượng (trên dữ liệu đã Winsorization)

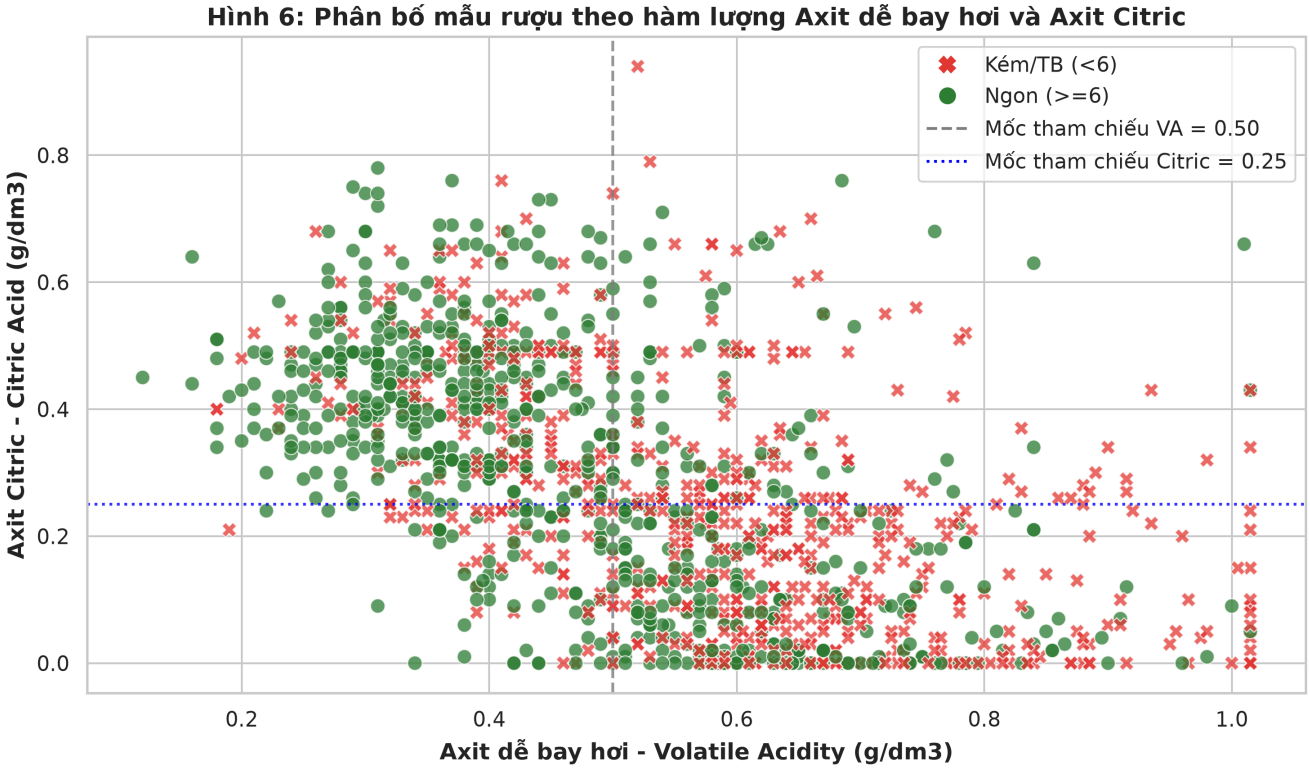
Nhận xét từ Heatmap & Kiểm định đa cộng tuyến (Centered VIF): Các yếu tố có tương quan thuận rõ nhất là alcohol (+0.48), sulphates (+0.33) và citric acid (+0.23); các yếu tố tương quan nghịch là volatile acidity (-0.39), total sulfur dioxide (-0.20), density (-0.19) và chlorides (-0.19). Mặc dù fixed acidity tương quan cặp khá cao với density (+0.67) và pH (-0.68), kết quả tính hệ số phóng đại phương sai Centered VIF ghi nhận: fixed acidity (7.27), density (7.08), các biến còn lại đều < 3.5. **Hai biến fixed acidity và density có mức đa cộng tuyến tương đối đáng chú ý (thuộc khoảng 5–10 thường gặp do tính chất liên kết vật lý chặt chẽ giữa tổng lượng axit và tỷ trọng), nhưng cả hai đều chưa vượt ngưỡng cảnh báo 10 đã chọn**. Cần theo dõi hoặc cân nhắc các mô hình ít nhạy cảm với đa cộng tuyến nếu phát triển mô hình hồi quy tuyến tính cổ điển.



Hình 5: Phân phối Violin - Boxplot của Alcohol và Volatile Acidity qua từng mức điểm quality (trên dữ liệu đã Winsorization)

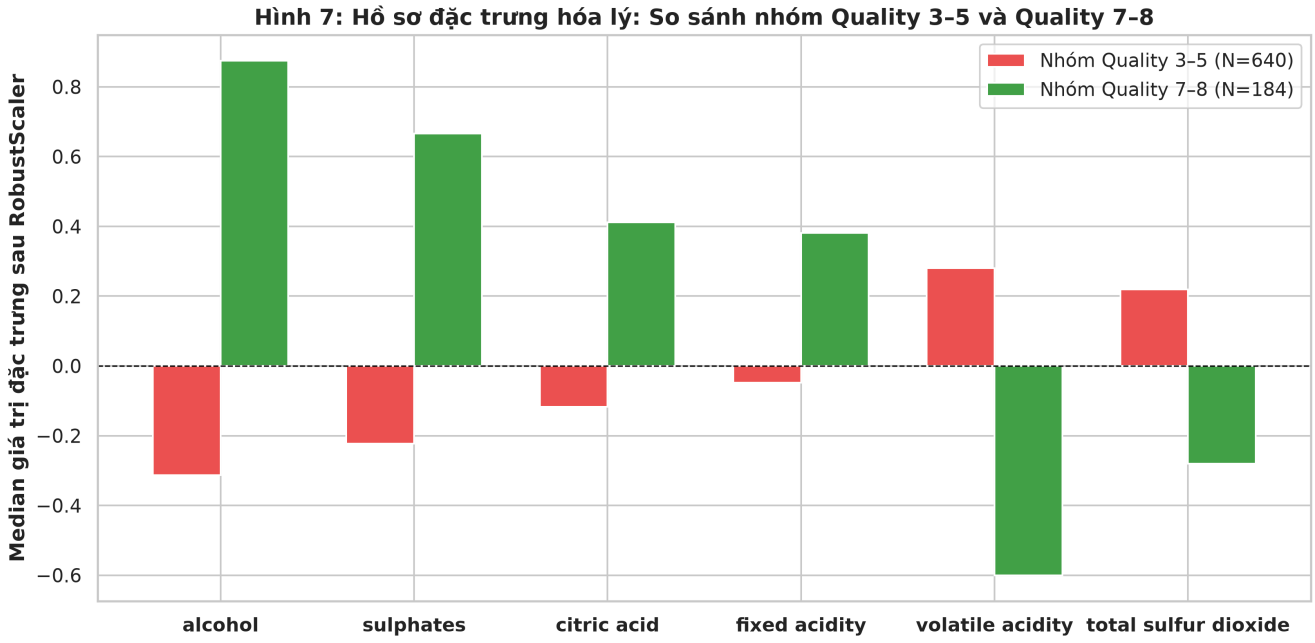
Nhận xét từ biểu đồ phân phối và bảng thống kê thực tế:

- *Nồng độ cồn trung bình:* Nhìn chung cao hơn ở các nhóm có điểm chất lượng cao, mặc dù xu hướng không tăng đơn điệu tại mọi mức điểm: điểm 3 (9.96%), điểm 4 (10.27%), điểm 5 (9.89%), điểm 6 (10.66%), điểm 7 (11.49%) và điểm 8 (12.10%).
- *Axit dễ bay hơi trung bình:* Nhìn chung có xu hướng giảm khi điểm chất lượng tăng: điểm 3 (0.81 g/dm³), điểm 4 (0.69 g/dm³), điểm 5 (0.58 g/dm³), điểm 6 (0.50 g/dm³), điểm 7 (0.40 g/dm³); tuy nhiên nhóm quality 8 ghi nhận mức tăng nhẹ so với nhóm quality 7 (0.43 g/dm³).



Hình 6: Phân bố mẫu rượu theo hàm lượng Axit dễ bay hơi và Axit Citric (Các đường nét đứt là mốc tham chiếu trực quan do nhóm đề xuất)

Nhận xét từ biểu đồ phân tán: Chú giải biểu đồ được khởi tạo chuẩn xác (Dấu X đỏ: Kém/TB <6; Chấm tròn xanh: Ngon ≥6; Đường nét đứt xám: Mốc tham chiếu VA = 0.50; Đường chấm xanh: Mốc tham chiếu Citric = 0.25). Đa số các mẫu điểm cao (chấm xanh) tập trung ở vùng axit bay hơi thấp và axit citric cao, trong khi các mẫu điểm thấp (dấu X đỏ) phân bố nhiều ở khu vực axit bay hơi cao.



Hình 7: Hồ sơ đặc trưng hóa lý: So sánh nhóm Quality 3–5 và Quality 7–8

Nhận xét từ bảng chênh lệch và biểu đồ so sánh: Biểu đồ so sánh giá trị Median sau RobustScaler giữa nhóm Quality 3–5 (N = 640) và nhóm Quality 7–8 (N = 184). Bảng số liệu cụ thể xuất từ thực nghiệm ghi nhận:

Chỉ số đặc trưng	Nhóm Quality 3–5 (N = 640)	Nhóm Quality 7–8 (N = 184)	Chênh lệch (Difference)
alcohol_scaled	-0.31	+0.88	**+1.19**
sulphates_scaled	-0.22	+0.67	**+0.89**
citric acid_scaled	-0.12	+0.41	**+0.53**
fixed acidity_scaled	-0.05	+0.38	**+0.43**
total sulfur dioxide_scaled	+0.22	-0.28	**-0.50**
volatile acidity_scaled	+0.28	-0.60	**-0.88**

GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

1. Tóm tắt các phát hiện nổi bật

1. Nồng độ cồn (alcohol) và sulphates có tương quan thuận có ý nghĩa thống kê với điểm chất lượng cảm quan, trong khi axit dễ bay hơi (volatile acidity) có mối tương quan nghịch mạnh nhất (được xác thực nhất quán qua cả hai phương pháp Pearson và Spearman trên toàn bộ 11 biến).
2. Đường dư không thể hiện tương quan tuyến tính hay đơn điệu có ý nghĩa thống kê với điểm chất lượng của dòng vang đỏ trong tập mẫu này (Pearson p = 0.481, Spearman p = 0.359).
3. Việc xử lý ngoại lệ bằng Winsorization giúp kiểm soát biên dữ liệu nhưng cần được ghi nhận minh bạch vì nó làm tăng nhẹ hệ số tương quan của sulphates và chlorides.

2. Đề xuất giải pháp ứng dụng thực tế

- *Vận hành sản xuất và kiểm soát quy trình lên men:* Theo dõi chặt chẽ nồng độ volatile acidity trong bồn ủ. Trong sản xuất rượu vang, chỉ số này tăng cao thường liên quan đến hoạt động của vi khuẩn axetic; cần kiểm soát nhiệt độ lên men và duy trì nồng độ SO_2 tự do thích hợp để hạn chế sự hình thành mùi giấm.
- *Khuyến nghị xây dựng hệ thống dự báo (Predictive Modeling):* Trong các nghiên cứu dự báo tiếp theo, nhóm đề xuất sử dụng `Pipeline` (như `sklearn.pipeline.Pipeline`). Tham số chuẩn hóa (fit scaler) cần được tính toán riêng biệt trên tập huấn luyện (Train set) trong từng fold của Cross-validation để ngăn ngừa rò rỉ dữ liệu (Data Leakage). Bước imputation chỉ bổ sung khi phát sinh missing values (tập dữ liệu hiện tại đạt 100% đầy đủ); bước encoding chỉ cần thiết khi tích hợp thêm các biến định danh hoặc phân loại trong tương lai.

3. Giới hạn dữ liệu và hướng mở rộng

- *Giới hạn:* Dữ liệu thu thập từ một vùng địa lý duy nhất (Vinho Verde, Bồ Đào Nha); tập dữ liệu không chứa thông tin về giống nho, năm mùa vụ (vintage), thời gian ủ thùng gỗ sồi, hay phân hạng thương mại và giá bán; biến mục tiêu quality bị mất cân bằng lớp ở các mức điểm cực 3 và 8.
- *Hướng mở rộng:* Thu thập thêm dữ liệu khí tượng mùa vụ; áp dụng các kỹ thuật giải thích mô hình như SHAP (SHapley Additive exPlanations) để định lượng mức độ đóng góp của từng thuộc tính hóa lý cho từng mẫu rượu cụ thể.

4. Tài liệu tham khảo (References)

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4), 547–553. https://doi.org/10.1016/j.dss.2009.05.016

UCI Machine Learning Repository. (2009). *Wine Quality*. https://doi.org/10.24432/C56S3T